

第七天

2019年6月15日 9:38

fasttext的原理

1. 架构

- a. 输入层：词语+N-gram之后的词语 ---》embedding
- b. 隐藏层
- c. 输出层

2. 层次化的softmax（对传统softmax的优化）

- a. 哈夫曼树：树的带权路径最短的二叉树
- b. 带权路径长度：从根结点到该结点之间的路径长度与该结点的权的**乘积**
- c. 哈夫曼树的构造方法：
 - i. 每次选择根节点权值最小的两棵树进行合并
- d. 哈夫曼编码：
 - i. 满足前缀编码的要求
 - ii. 把字母的出现次数叶子节点的权值，构造哈夫曼树
- e. 好处：减少计算的时间复杂度，提高效率

3. fasttext的负采样（对传统的softmax的优化）

- a. 采样：
 - i. 数据根据label的数量分为V份，每一份是和数量的3/4次方成比例
 - ii. 之后从数据中随机的选择neg个负样本
- b. 训练：
 - i. 整个训练过程通过二分类的方式进行训练，提高当前正样本的概率
 - ii. 损失=正样本的损失+neg个负样本的损失
- c. 好处：
 - i. 提高训练速度
 - 1) 训练数据少
 - 2) 把多分类转化为2分类进行进行训练
 - ii. 提高模型的稳健性，负样本可以模拟噪声数据

4. Seq2seq模型的原理

- a. 编码器：RNN
 - i. 去理解句子
- b. 解码器：RNN
 - i. 根据句子向量，得到输出

- ii. 为什么可以有多个输出
 - 1) 把前一次的输出和hidden_state作为下一次的输入
- iii. 什么时候停止多个输出
 - 1) 在训练的时候训练数据的target最后添加<EOS>
 - 2) 在预测的时候预测结果为EOS, 则停止

4. seq2seq的DEMO

- a. 文本转化为序列 (数字序列, torch.LongTensor)
- b. 使用序列, 准备数据集, 准备Dataloader
 - i. 随机种子, random.seed(9)
 - 1) 使用同一个随机种子, 每次随机的结果是一样的
 - ii. add_eos:
 - 1) 训练集中, target需要有EOS, 告诉模型EOS是结束
 - 2) 预测的时候, 预测出EOS, 意味着该结束
- c. 完成编码器
 - i. 为了加速gru、lstm的计算, 可以对句子进行打包和解包的操作
 - 1) torch.nn.utils.rnn.pack_padded_sequence
 - 2) nn.utils.rnn.pad_packed_sequence
 - 3) 打包的方法需要batch的数据按照句子的长度降序排序
- d. 完成解码器
 - i. decoder最开始的输入是一个[batch_size,1]的SOS ,
 - ii. 是一个在每个时间步循环
 - 1) output_t,hidden = forward_step(input,hidden)
 - 2) input是[batch_size,1],hidden和encoder hidden相同
 - 3) input先进行embedding
 - 4) 结果通过gru处理得到output,[batch_size,1,hidden_size]
 - 5) 结果进行变形为, 【batch_size,vocab_Size】,进行log_softmax转化为概率
 - iii. 把每个时间步的输出保存, 用来和target计算loss
 - iv. 当前时间步的输出, 取概率最大的位置, 作为预测值, 作为下一个时间步的输入
- e. 完成seq2seq模型
 - i. encode和decoder放到一起使用
- f. 完成模型训练的逻辑, 进行训练
 - i. loss怎么定义

- 1) 每个时间步是在进行多分类, 类别数量=词典数量
 - 2) outputs:[batch_Size,max_Len,vocab_size],target:[batch_size,max_len]
 - 3) 对outputs,和target进行变形, 让batch_size*max_len,
 - 4) 之后的损失计算和普通多分类一样
- g. 完成模型评估的逻辑, 进行模型评估
- i. 需要保存每个时间步的预测结果, 供后续进行准确率的计算

作业:

使用对联数据, 训练模型, 能够输入上联, 预测下联

数据地址: <https://github.com/wb14123/couplet-dataset>