

第二天

2019年6月8日 9:53

梯度下降

1. 梯度：向量，值是导数，方向是变化最快的方向
2. 导数的计算： $\nabla w = f(w+d) - f(w-d) / 2d$ (d 非常小)
3. 更新参数 w ： $w = w - \alpha \nabla w$

链式法则：把复杂的函数用更小的变量去表示包含 x 的部分

反向传播：先计算最后一层的偏导，之后再计算倒数第二层...

1. 链式法则：
2. 计算图：使用图来表示一个计算，用一个中间变量来表示每一次的计算结果

pytorch实现线性回归

1. tensor 中的`require_grad`参数
 - a. 设置为`True`，表示会记录该tensor的计算过程
2. tensor中的`grad_fn`属性
 - a. 用来保存计算的过程
3. tensor不保留计算过程
 - a. `with torch.no_grad()`:
4. 反向传播：
 - a. `out.backward()`
 - b. 导数保存在`tensor.grad`,默认梯度会累加
5. `tensor.data`
 - a. 获取tensor中值的引用操作
6. `tensor.numpy ()`
 - a. 当tensor中需要计算梯度的时候，`grad_fn`不为`None`的时候，`tensor.data.numpy()`、`tensor.detach().numpy()`
7. 实现线性回归的逻辑
 - a. 准备数据
 - b. 初始化参数，进入循环（参数的梯度置为0），计算预测值
 - c. 计算loss, `loss.backward()`计算梯度
 - d. 更新参数
8. pytorch通过api完成模型和训练

- a. api
 - i. nn.Module 构造模型
 - 1) init: 自定义的方法实现的位置
 - 2) forward: 完成一次向前计算的过程
 - ii. optimizer优化器类
 - 1) torch.optim.SGD/Aadm
 - 2) 流程:
 - a) 实例化 Aadm(model.parameters(),lr)
 - b) 梯度置为0, optimizer.zero_grad()
 - c) 反向传播, 计算梯度: loss.backward()
 - d) optimizer.step() 参数的更新
 - iii. 损失函数
 - 1) 损失函数对象torch.nn提供
- b. 训练的过程:
 - i. 实例化模型
 - ii. 实例化损失函数
 - iii. 实例化优化器类
 - iv. 进入循环:
 - 1) 梯度置为0
 - 2) 调用模型得到预测值
 - 3) 调用loss函数, 得到损失
 - 4) loss.backward() 进行梯度计算
 - 5) optimizer.step()
- c. 注意点
 - i. model.eval() #把模型置为评估模型
 - 1) model.training = False
 - ii. GPU上运行代码
 - 1) 自定义的tensor.to(device)
 - 2) model.to(device)

优化算法:

1. 梯度下降: 把所有的数据传入模型, 计算平均梯度, 更新参数, 缺点: 慢
2. 随机梯度下降: 选一条数据进行参数的更新. 缺点: 容易受到噪声数据的影响
3. 批梯度下降: 每次选择一波数据进行参数的更新. 缺点: 梯度的变化幅度可能会很大, 在最小值附件徘徊
4. 动量法: 把历史的梯度考虑进去. 更新参数时候使用梯度=历史梯度的指数加权平均
5. adagrad : 更新参数的时候, 使用自适应的学习率, = 学习率/历史梯度的平方
6. rmsprop: 使用自适应的学习率, = 学习率/历史梯度的平方的指数加权平均
7. adam: 动量法和RMSprop的结合版本, 既考虑梯度 (使用梯度的指数加权平均), 又考

虑学习率（让学习率除以历史梯度的平方的指数加权平均）